使用 RNN 进行文本分类

原创 zzzkkkk 要努力的小正 2020-11-16

此文本分类教程将在 IMDB 大型电影评论数据集上训练循环神经网络,以进行情感分析。

设置

```
1 import tensorflow_datasets as tfds
2 import tensorflow as tf
```

导入 matplotlib 并创建一个辅助函数来绘制计算图:

```
import matplotlib.pyplot as plt

def plot_graphs(history, metric):
   plt.plot(history.history[metric])
   plt.plot(history.history['val_'+metric], '')
   plt.xlabel("Epochs")
   plt.ylabel(metric)
   plt.legend([metric, 'val_'+metric])
   plt.show()
```

设置输入流水线

IMDB 大型电影评论数据集是一个二进制分类数据集——所有评论都具有正面或负面情绪。 使用 TFDS 下载数据集。

WARNING:abs1:TFDS datasets with text encoding are deprecated and will be removed in a fu

Downloading and preparing dataset imdb_reviews/subwords8k/1.0.0 (download: 80.23 MiB, ge

Shuffling and writing examples to /home/kbuilder/tensorflow_datasets/imdb_reviews/subwor Shuffling and writing examples to /home/kbuilder/tensorflow_datasets/imdb_reviews/subwor Shuffling and writing examples to /home/kbuilder/tensorflow_datasets/imdb_reviews/subwor Dataset imdb_reviews downloaded and prepared to /home/kbuilder/tensorflow_datasets/imdb_

数据集 info 包括编码器 (tfds.features.text.SubwordTextEncoder)。

```
1 encoder = info.features['text'].encoder
2 print('Vocabulary size: {}'.format(encoder.vocab_size))
```

Vocabulary size: 8185

此文本编码器将以可逆方式对任何字符串进行编码,并在必要时退回到字节编码。

```
1 sample_string = 'Hello TensorFlow.'
2
3 encoded_string = encoder.encode(sample_string)
4 print('Encoded string is {}'.format(encoded_string))
5
6 original_string = encoder.decode(encoded_string)
7 print('The original string: "{}"'.format(original_string))
```

Encoded string is [4025, 222, 6307, 2327, 4043, 2120, 7975] The original string: "Hello TensorFlow."

```
1 assert original_string == sample_string
```

```
for index in encoded_string:
print('{} ----> {}'.format(index, encoder.decode([index])))
```

```
4025 ----> Hell
222 ----> o
6307 ----> Ten
2327 ----> sor
4043 ----> Fl
```

```
2120 ----> ow 7975 ----> .
```

准备用于训练的数据

接下来,创建这些编码字符串的批次。使用 padded_batch 方法将序列零填充至批次中最长字符串的长度:

```
1 BUFFER_SIZE = 10000
2 BATCH_SIZE = 64

1 train_dataset = train_dataset.shuffle(BUFFER_SIZE)
2 train_dataset = train_dataset.padded_batch(BATCH_SIZE)
3
4 test_dataset = test_dataset.padded_batch(BATCH_SIZE)
```

创建模型

构建一个 tf. keras. Sequential 模型并从嵌入向量层开始。嵌入向量层每个单词存储一个向量。调用时,它会将单词索引序列转换为向量序列。这些向量是可训练的。(在足够的数据上)训练后,具有相似含义的单词通常具有相似的向量。

与通过 tf. keras. layers. Dense 层传递独热编码向量的等效运算相比,这种索引查找方法要高效得多。

循环神经网络 (RNN) 通过遍历元素来处理序列输入。RNN 将输出从一个时间步骤传递到其输入,然后传递到下一个步骤。

tf. keras. layers. Bidirectional 包装器也可以与 RNN 层一起使用。这将通过 RNN 层向前和向后传播输入,然后连接输出。这有助于 RNN 学习长程依赖关系。

```
model = tf.keras.Sequential([
    tf.keras.layers.Embedding(encoder.vocab_size, 64),
    tf.keras.layers.Bidirectional(tf.keras.layers.LSTM(64)),
    tf.keras.layers.Dense(64, activation='relu'),
    tf.keras.layers.Dense(1)
]
```

请注意,我们在这里选择 Keras 序贯模型,因为模型中的所有层都只有单个输入并产生单个输出。如果要使用有状态 RNN 层,则可能需要使用 Keras 函数式 API 或模型子类化来构建模型,以便可以检索和重用 RNN 层状态。有关更多详细信息,请参阅 Keras RNN 指南。

编译 Keras 模型以配置训练过程:

训练模型

Epoch 5/10

Epoch 6/10

Epoch 7/10

```
1 test_loss, test_acc = model.evaluate(test_dataset)
2
3 print('Test Loss: {}'.format(test_loss))
4 print('Test Accuracy: {}'.format(test_acc))
```

上面的模型没有遮盖应用于序列的填充。如果在填充序列上进行训练并在未填充序列上进行 测试,则可能导致倾斜。理想情况下,您可以使用遮盖来避免这种情况,但是正如您在下面看 到的那样,它只会对输出产生很小的影响。

如果预测 >= 0.5,则为正,否则为负。

```
1 def pad_to_size(vec, size):
2  zeros = [0] * (size - len(vec))
3  vec.extend(zeros)
4  return vec
```

```
def sample_predict(sample_pred_text, pad):
    encoded_sample_pred_text = encoder.encode(sample_pred_text)


if pad:
    encoded_sample_pred_text = pad_to_size(encoded_sample_pred_text, 64)
encoded_sample_pred_text = tf.cast(encoded_sample_pred_text, tf.float32)
predictions = model.predict(tf.expand_dims(encoded_sample_pred_text, 0))

return (predictions)
```


[[-0.11829309]]

[[-1.162545]]

```
1 plot_graphs(history, 'accuracy')
```



```
1 plot_graphs(history, 'loss')
```



堆叠两个或更多 LSTM 层

Keras 循环层有两种可用的模式,这些模式由 return_sequences 构造函数参数控制:

• 返回每个时间步骤的连续输出的完整序列 (形状为 (batch_size, timesteps, output_features) 的 3D 张量)。

仅返回每个输入序列的最后一个输出(形状为(batch_size, output_features)的 2D 张量)。

```
model = tf.keras.Sequential([
    tf.keras.layers.Embedding(encoder.vocab_size, 64),
    tf.keras.layers.Bidirectional(tf.keras.layers.LSTM(64, return_sequences=Tr
    tf.keras.layers.Bidirectional(tf.keras.layers.LSTM(32)),
    tf.keras.layers.Dense(64, activation='relu'),
    tf.keras.layers.Dropout(0.5),
    tf.keras.layers.Dense(1)
    ])
```


```
history = model.fit(train_dataset, epochs=10,
validation_data=test_dataset,
validation_steps=30)
```


```
1 test_loss, test_acc = model.evaluate(test_dataset)
2
3 print('Test Loss: {}'.format(test_loss))
4 print('Test Accuracy: {}'.format(test_acc))
```


[[-2.6377363]]

[[-3.0502243]]

```
1 plot_graphs(history, 'accuracy')
```







检查其他现有循环层,例如 GRU 层。

完毕!!!!!!!!!!!