扔掉代码表！用RNN“破解”摩斯电码

原创 黑科技 AI前线 2018-03-15

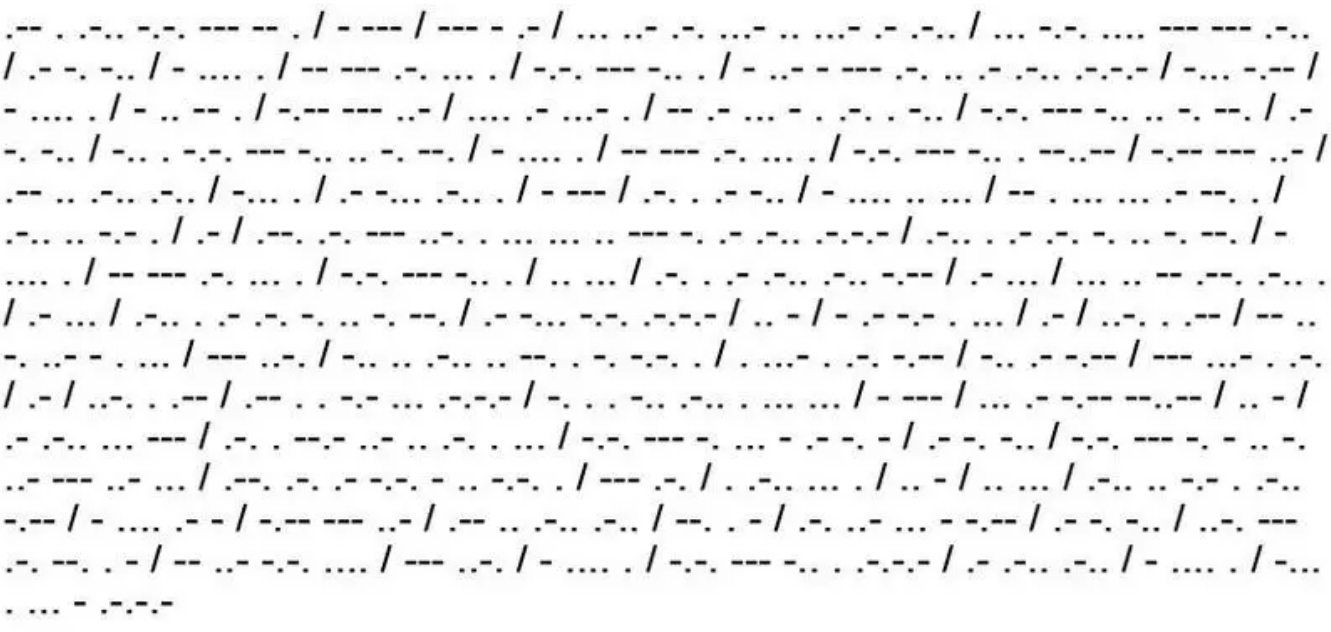

作者 | Sandeep Bhupatiraju
译者 | Liu Zhiyong
编辑 | Debra Chen

AI 前线导读：100 多年前，在美国，人们利用 Morse 电码发出了人类历史上的第一份电报，从此人类又揭开一页崭新的篇章。Morse 电码的问世，对人类社会发生全面而深远的影响，极而言之甚至改变了人类历史的发展方向。只不过随着当代信息的爆炸式发展，多种通信方式渐渐将方式单一的电报挤到了角落。电报从最初先驱者的试验品，于战争年代发展到顶峰，最后在现代被基层群众所遗忘。虽然目前仍然有坚持使用电报的机构和民间爱好者，但是那点可悲的使用量完全无法和电话等通信方式相抗衡。要解读 Morse 电码编码的电文，就需要一本代码表才能知道电文的意思。如果没有代码表怎么破？可以用 RNN 来破解 Morse 电码吗？当然可以！这是很好的点子。一位研究数学和数据科学的大牛 Sandeep Bhupatiraju 就撰写了一篇文章：“Cracking” Morse code with RNNs，让我们看看如何使用 RNN 来“破解”Morse 电码？

更多干货内容请关注微信公众号“AI 前线”，（ID：ai-front）

剧透警告：其实 Morse 电码并不需要破解。它很有用，因为可以用最少的设备来发送消息。我之所以说它不需要破解，是因为这种代码是众所周知的，点和破折号的组合并不是什么秘密。但是从理论上讲，它是一种替代密码（substitution cipher）：每个字母和每个数字都是使用点和破折号来表示，如下图所示：

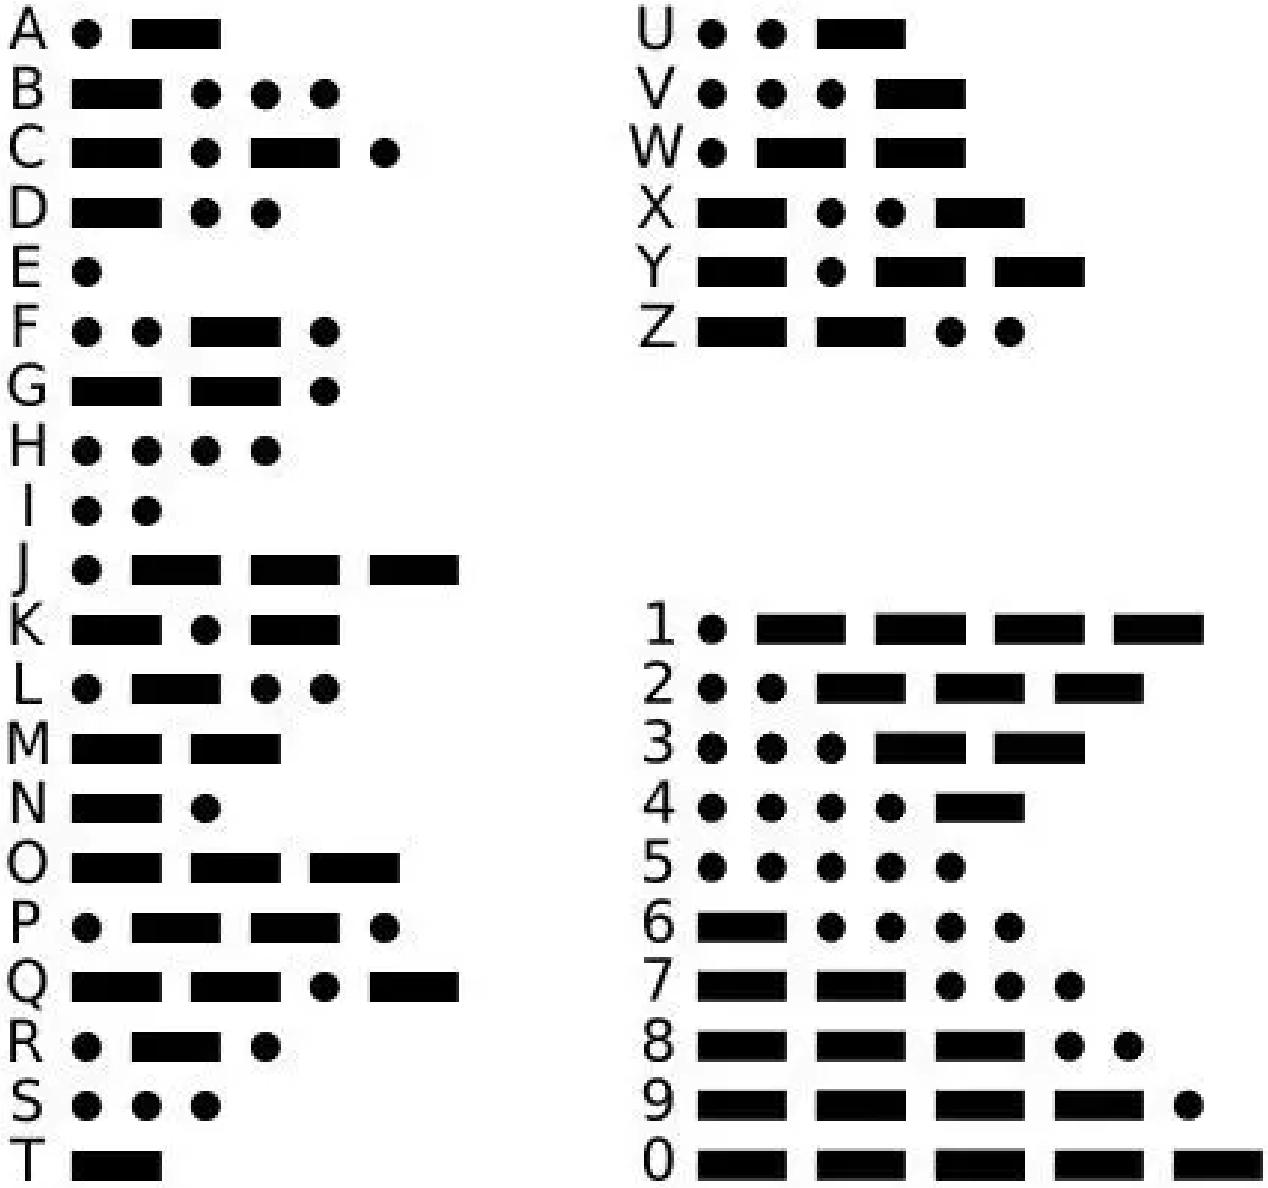

> AI 前线：Morse 电码是一种时通时断的信号代码，通过不同的排列顺序来表达不同的英文字母、数字和标点符号。它发明于 1837 年。Morse 电码是一种早期的数字化通信形式，但是它不同于现代只使用零和一两种状态的二进制代码，它的代码包括五种： 点、划、点和划之间的停顿、每个词之间中等的停顿以及句子之间长的停顿。

让我们先不要怀疑，假设我们收到了 Morse 电码的消息，但我们不知道如何解读。假设我们还有一些代码示例和它们对应的单词。现在，我们可以推测它是一种替代密码，然后我们可以最终计算出每个字母的代码，从而解码消息。

或者，我们可以构建一个 encoder-decoder 模型 来猜测（几乎）所有的单词！作为受虐狂，我们当然会选择后者。照这样说，让我们猛拍一下堂·吉诃德的战马 Rocinante，开始大战风车的征程。

> AI 前线：Rocinante，西班牙语，驽骍难得 [音译]，《堂·吉诃德》中堂·吉诃德所骑的马的名字。

这里有个手头问题: 我们有几个编码序列及对应的可理解的例子。使用这些例子，我们必须学习一些模式，并使用这些信息来预测新的编码标记（单词）可能会是什么。与我们预测数值结果的常见回归问题不同，我们手头有一些序列到序列（sequence-to-sequence）的学习问题，在数据中有时间结构。这是递归神经网络（RNN）可能有用的一个即时提示（它用于语音和语音数据的 RNN，以及用于图像数据的 CNN 和用于图像字母的 RNN 组合）。粗略地说，这属于一类问题：也包含了机器翻译的问题；这个模型的结构在这里起到了启发的作用。有关此主题的更多信息请参阅 [1]。限于篇幅我们不会赘述 RNN 的理论，但对于这个主题的简要介绍请参考文献 [2] 的一系列文章。

如果你想知道这个问题是否可以用不同的方法来解决，答案是：YES。马尔可夫链蒙特卡罗方法（Markov Chain Monte Carlo）会得到类似的结果。在这种情况下，我们将会遵循优秀论文 [3] 中第一个例子所提到的过程。

> AI 前线：马尔可夫链蒙特卡罗算法（简写为 MCMC）的核心思想是找到某个状态空间的马尔可夫链，使得该马尔可夫链的稳定分布就是我们的目标分布 p(x)。这样我们在该状态空间进行随机游走的时候，每个状态 x 的停留时间正比于目标概率 p(x)。在用 MCMC 进行抽样的时候，我们首先引进一个容易抽样的参考分布 q(x)，在每步抽样的过程中从 q(x) 里面得到一个候选样本 y，然后按照一定的原则决定是否接受该样本，该原则的确定就是要保证我们得到的原本恰好服从 p(x) 分布。

马尔可夫链，因安德烈·马尔可夫（A.A.Markov，1856 - 1922）得名，是指数学中具有马尔可夫性质的离散事件随机过程。该过程中，在给定当前知识或信息的情况下，过去（即当前以前的历史状态）对于预测将来（即当前以后的未来状态）是无关的。

在马尔可夫链的每一步，系统根据概率分布，可以从一个状态变到另一个状态，也可以保持当前状态。状态的改变叫做转移，与不同的状态改变相关的概率叫做转移概率。随机漫步就是马尔可夫链的例子。随机漫步中每一步的状态是在图形中的点，每一步可以移动到任何一个相邻的点，在这里移动到每一个点的概率都是相同的（无论之前漫步路径是如何的）。

梗概

粗略地说，我们想从 (x_1,...,x_n) 输入序列预测输出序列 (y_1,...,y_m)，这就涉及了条件概率（conditional probability）的学习。

> AI 前线：条件概率是指事件 A 在另外一个事件 B 已经发生条件下的发生概率。条件概率表示为：P（A|B），读作“在 B 条件下 A 的概率”。条件概率可以用决策树进行计算。条件概率的谬论是假设 P(A|B) 大致等于 P(B|A)。

$$P(y_1, \ldots, y_m \mid x_1, \ldots, x_n).$$

这里的主要障碍是，从可变尺寸的输入来预测可变尺寸的输出。在元级这一层次上，是通过将两个 RNN 组合在一起来解决的，其中，第一个 RNN 将可变尺寸的输入映射到固定尺寸的输出，另一个 RNN 接受固定尺寸输入并返回可变尺寸的输出。固定尺寸的中间向量，成为上下文矢量（context vector），它将信息从输入序列中封装起来，每次输入一个字符。产生上下文矢量的机制是使 RNN 对于捕获时间结构有用：上下文矢量是最终的 timestep 或它的某些函数之后的隐藏状态。上述条件概率使用链式法则（chain rule） 计算的。

> AI 前线：链式法则是微积分中的求导法则，用于求一个复合函数的导数，是在微积分的求导运算中一种常用的方法。复合函数的导数将是构成复合这有限个函数在相应点的 导数的乘积，就像锁链一样一环套一环，故称链式法则。可见搞人工智能，学好数学非常重要。

$$P(y_m, \ldots, y_1 \mid x_1, \ldots, x_n) = \prod_{i=2}^{m} P(y_i \mid y_{i-1}, \ldots y_1, h),$$

其中，h 是上下文矢量。最后，可以使用 softmax 函数来计算上述方程右边的条件概率，该函数将字符 y_{i-1},...,y_1 的独热编码（one-hot encoded）矢量作为输入，在第二 RNN 中的递归层（recurrent layer）的输出和上下文矢量。这里使用的特定类型的 RNN

是 LSTM，有效克服了 Simple-RNN 的局限性，Simple-RNN 受到渐变问题的影响，并能够更好地捕获远程依赖关系。

> AI 前线：Simple-RNN 是最简单的循环神经网络，它是 LSTM 的基础。Simple-RNN 与 BP 一样都有前馈层与反馈层。但是 Simple-RNN 引入了基于时间 (状态) 的循环机制。

数据准备

我们将引入一个特殊的字符（11）来表示每个字母的代码之间的空格。例如，SOS 的代码将表示为：...11---*...（替换...---...）。我们这样做是为了确保与给定代码相对应的单词是唯一的。接下来，我们将使用已编译数据集（words_alpha）中的英文单词，而不是用随机生成的字母集作为我们的数据。为了获得数据的感觉，参看下图所示的单词长度的直方图。从直方图上可以看出，长度超过 5 个字母的单词要比短的单词多。

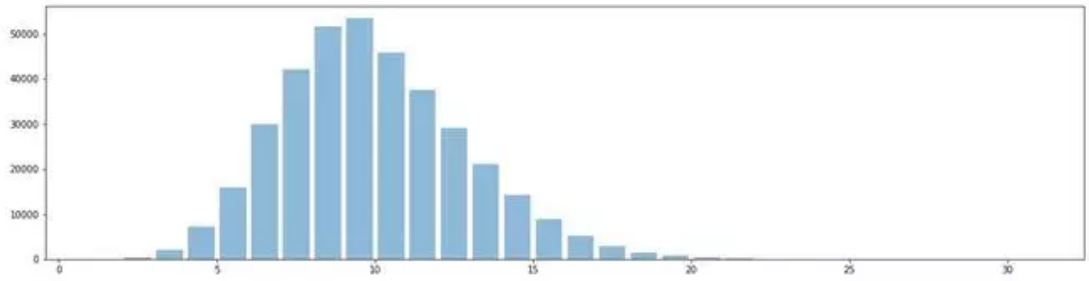

对包含编码单词的数据进行训练的网络，一般会预测长的单词。请记住，网络并不会计算出生成数据的“公式”，也就是说，它并不会学习图 1 中的图表。

我们开始数据准备工作，构建一个函数，将所输入的英文单词编码为它的 Morse 电码并输出。

```
import random
import numpy as np
import matplotlib.pyplot as plt

# construct the Morse dictionary
alphabet = " ".join("abcdefghijklmnopqrstuvwxyz").split()

values = ['.-', '-...', '-.-.', '-..', '.', '..-.', '--.', '....', '..', '.---', '-.-', '.
-..', '--', '-.','---', '.--.', '--.-',.-.', '...', '-', '..-', '...-', '.--', '-..-', '-.--
', '--..']

morse_dict = dict(zip(alphabet, values))

def morse_encode(word):
    return "*".join([dict_morse_encode[i]for i
        in " ".join(word).split()]
```

为了说明的目的，我们将从给定的固定长度的单词生成训练和验证数据。在这里，我们将这个长度固定为 9，因为长度为 9 的字数足够大（参见上述直方图）。注意，此举将意味着来自网络的输出单词的长度将是固定的，但是输入的 Morse 电码并不一定都是相同的长度。假定我们知道每个字母的编码长度最长是 4（其实我们不用这个特定的假设，可以选择的长度最长的 Morse 电码 max_length_x 来训练数据。）因此，如果单词的长度为 n ，那么与其对应的 Morse 电码的长度最多为 4n+(n-1)，其中 n-1 对应的是 11s 的数量。我们用左边的空格填充代码，使它们的长度相同，这意味着我们输入字符的词汇表是 { ‘.’ ， ‘—’ ， ‘*’ ， ‘ ’ }。一般而言，我们让输出的字符词汇表是所有字母和空格的特殊字符。回到关于网络猜测长单词的评论，我们的意思是，由于长单词的数量会造成不平衡，因此网络将会倾向于猜测更少的空格。在下面的代码片段中，output_list 将包含英文单词，input_list 将包含填充的 Morse 电码。

```
import random

word_len = 9
max_len_x = 4*word_len + (word_len-1)
max_len_y = len_word

def data_gen(n):

    with open('words_alpha.txt', 'r') as f:
        all_words = f.read().lower().split('\n')
        words = [word for word in all_words if len(word)==n]

        # Shuffle the list since the words are ordered
        random.shuffle(words)

        g_out = lambda x: ' '*(max_len_y -len(x)) + x
        output_list = [g_out(word) for word in words]

        g_in = lambda x: morse_encode(x)+' '*(max_len_x - len(morse_encode(x)))
        input_list = [g_in(word) for word in words]

        return output_list, input_list

output_list, input_list = data_gen(9)
```

现在，我们构建输入中字符的一个独热编码矢量，使输入数据适合神经网络。为此，我们构建了一个类对象（类似于 Keras 文档中的例子），它将有助于编码和解码，并将 Morse 电码和英语单词解码。我们将类分配给具有适当字符集的对象。

> AI 前线：独热编码即 One-Hot 编码，又称一位有效编码，其方法是使用 N 位状态寄存器来对 N 个状态进行编码，每个状态都有它独立的寄存器位，并且在任意时候，其中只有一位有效。

```
class CharTable(object):

    def __init__(self, chars):
        self.chars = sorted(set(chars))
        self.char_indices = dict((c, i) for i, c in enumerate(self.chars))
        self.indices_char = dict((i, c) for i, c in enumerate(self.chars))

    def encode(self, token, num_rows):
        x = np.zeros((num_rows, len(self.chars)))
        for i, c in enumerate(token):
            x[i, self.char_indices[c]] = 1
        return x

    def decode(self, x, calc_argmax=True):
        if calc_argmax:
            x = x.argmax(axis=-1)
        return ''.join(self.indices_char[x] for x in x)

# we include the white space as a character in both cases below.
chars_in = '*-. '
chars_out = 'abcdefghijklmnopqrstuvwxyz '

ctable_in = CharTable(chars_in)
ctable_out = CharTable(chars_out)
```

将数据拆分，生成一个训练集 x_train，从整个数据集 x，y 的四分之一中提取出 y_train，我们将保留剩下的四分之三作为验证集 x_val、y_val。注意，我们最好将训练集的一部分作为验证集，其余的作为测试集，但考虑我们是随便弄的设置，我们对模型构建更感兴趣，而非参数调优。现在，我们已经准备好了训练和测试（验证）数据，并且可以继续对网络进行修改。

```
x = np.zeros((len(input_list), max_len_x, len(chars_in)))
y = np.zeros((len(output_list), max_len_y, len(chars_out)))

for i, token in enumerate(input_list):
    x[i] = ctable_in.encode(token, max_len_x)
for i, token in enumerate(output_list):
    y[i] = ctable_out.encode(token, max_len_y)

m = len(x)// 4
(x_train, x_val) = x[:m], x[m:]
(y_train, y_val) = y[:m], y[m:]
```

构建神经网络的最简单方法是使用 Keras 模型和顺序 API。由于我们不需要 TensorFlow 的全部功能和灵活性，所以我们选择了 Keras。

模型结构 (Encoder-Decoder 模型)

我们所选的模型拓扑结合了简单的 RNN 的强大变体，称为长短期记忆（Long Short Term Memory，LSTM）网络。

> AI 前线：长短期记忆网络是一种时间递归神经网络，适合于处理和预测时间序列中间隔和延迟相对较长的重要事件。基于长短期记忆网络的系统可以实现机器翻译、视频分析、文档摘要、语音识别、图像识别、手写识别、控制聊天机器人、合成音乐等任务。

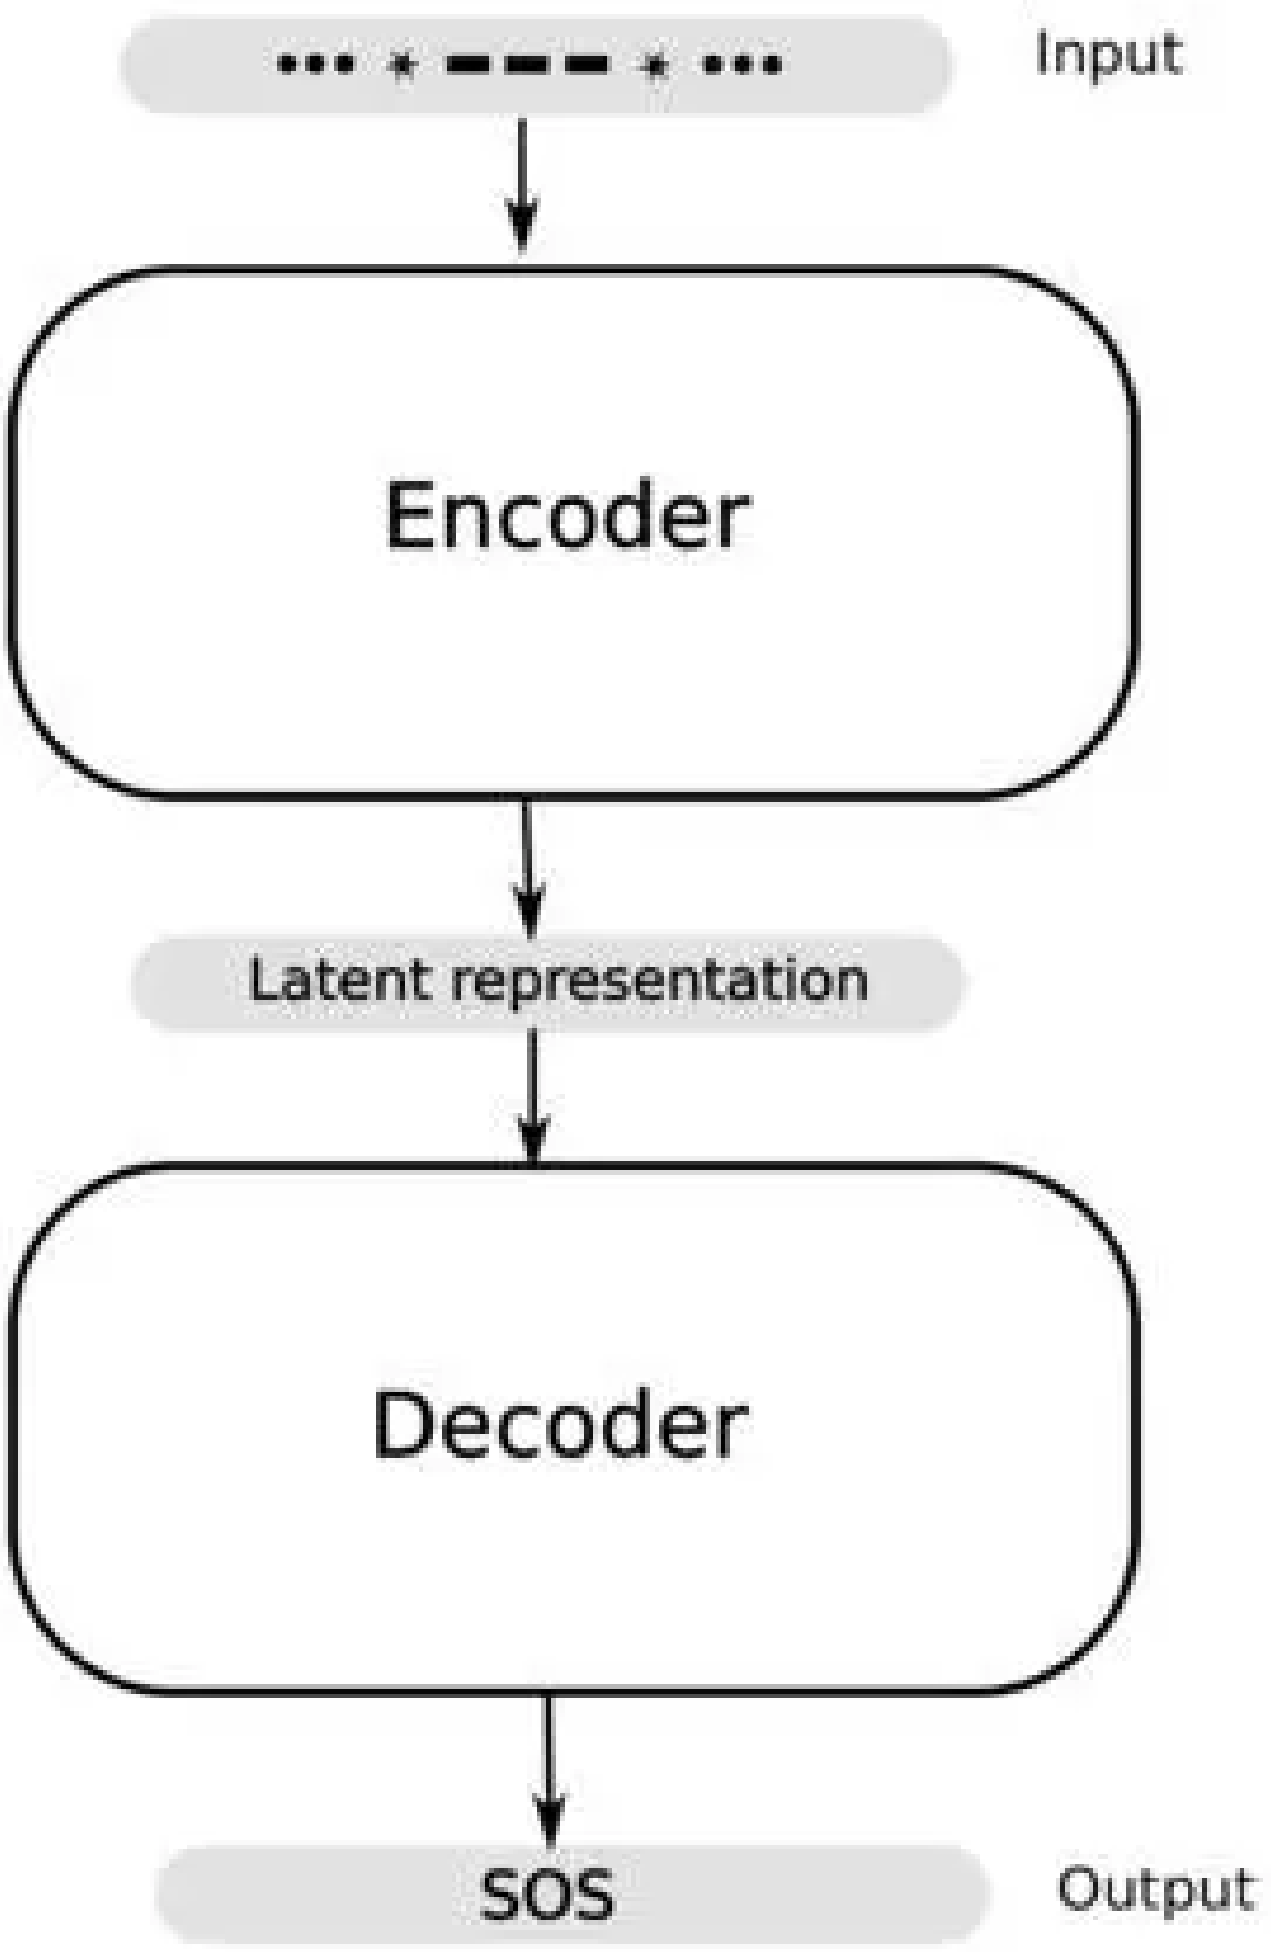
Input
Encoder
Latent representation
Decoder
SOS
Output

第一个 LSTM 用作编码器，接受一个可变长度的输入序列，每次一个字符，并将其转换为固定长度的内部潜在表示。另一个 LSTM 则作为解码器，将潜在的表示作为输入，并将其输出传递到一个密集层，该层使用 softmax 函数，每次预测一个字符。

该模型的编码器和解码器组件可能具有多层 LSTM，通常并不清楚哪种拓扑最适合使用。一般来说，对机器翻译而言，深层网络工作得更好。根据经验法则，我们期望多层能够学习更高层次的时间表示，因此当数据具备了一些层次结构时，我们就会使用它。对我们来说，每层有一层就足矣。

该模型使用 Sequential() 构建，并且每次只添加一个层。第一个 LSTM 层将 3D 张量作为输入，并要求用户指定输入维度。这可以用代码中指定的 input_shape 简单地完成，其中第一个组件表示时间步骤的数量，第二个组件表示特征的数量。对我们来说，特征的数量就是输入序列的词汇表中元素的数量，也就是 4，因为我们有“.”、“-”、“*”和空白字符“”。由于我们每次只提供一个独热编码矢量，因此时间步骤的数量就是 max_len_x。我们还将指定层中的内存单元（或块）的数量（此处用 latent_dim 参数表示，我们使用 256），这是潜在表示的维度。请注意，我们希望将 LSTM 的最终隐藏状态作为潜在表示返回，这包含了来自所有时间步骤的信息，即全部输入序列。如果我们使用 return_sequences = true 选项，那么将得到每个时间步骤的隐藏状态的输出，但这只包含到该步骤的序列信息。

```
model = Sequential()
model.add(layers.LSTM(latent_dim, input_shape=(max_x_length, len(chars_in))))
```

这就得到了简单的编码器模型。我们将构建一个类似的层作为解码器。但上面的代码片段的输出是个 2D 数组。我们通过使用方便的 RepeatVector 层重复输出时间数量 max_len_y，将其转换为 3D 张量，并作为下一个 LSTM 层（解码器）。现在，我们在这个 LSTM 中使用 return_sequences = True 选项来输出隐藏状态序列，我们需要使用这些信息进行预测。为此，我们使用一个 TimeDistibuted 密集层，它输出一个长度为 max_len_y 的矢量，我们使用 softmax 激活函数来选择最有可能的字母。为了快速了解 TimeDistributed 层的目的，请参阅 Jason Brownlee 撰写的博文：How to Use the TimeDistributed Layer for Long Short-Term Memory Networks in Python。

https://machinelearningmastery.com/timedistributed-layer-for-long-short-term-memory-networks-in-python/

```
model.add(layers.LSTM(latent_dim, return_sequences=True))
model.add(layers.TimeDistributed(layers.Dense(len(chars_out))))
model.add(layers.Activation('softmax'))
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
model.summary()
```

以下是对网络和各种输入、输出维度的快速摘要。

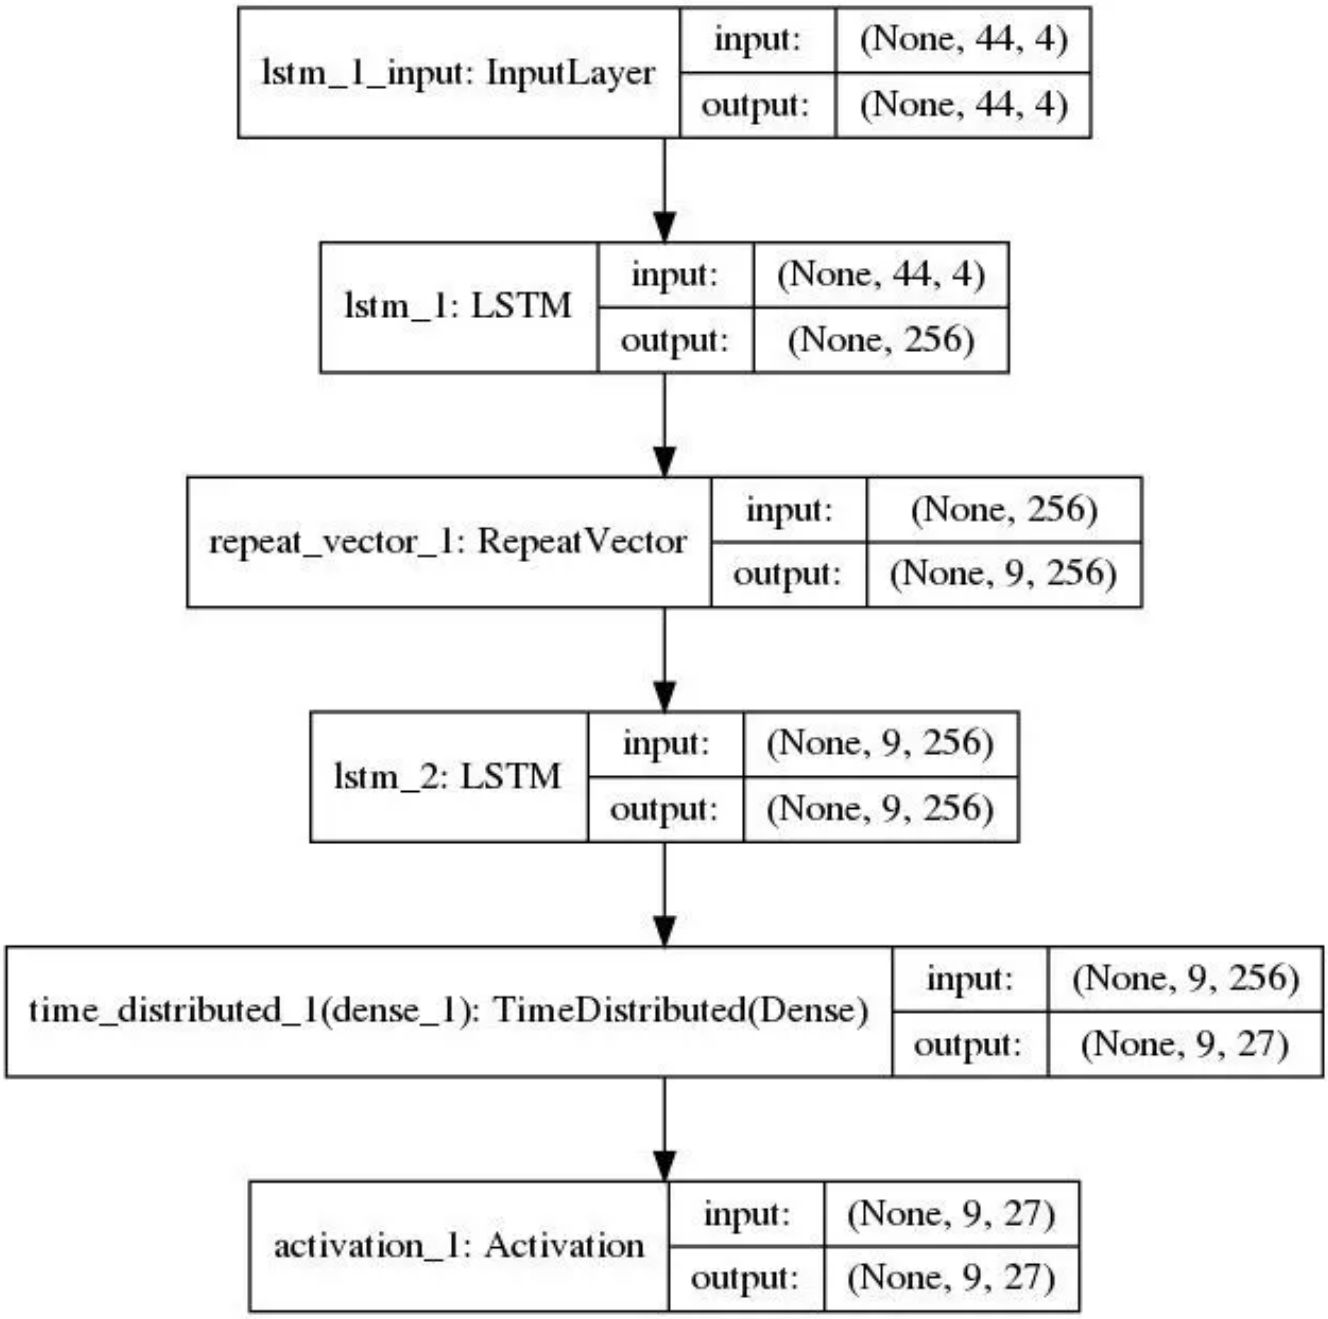

我们将模型拟合到数据中，在集合 x_train、y_train 上进行训练，并使用 x_val 和 y_val 来查看我们的工作情况。需要设置的最后一组参数是轮数（epochs）的数量和批大小。批大小是在梯度下降算法中通过网络传递的训练集的大小，然后对网络中的权重进行更新。通常批大小就是计算机内存可处理的最大值。一个轮数是通过这些批次的训练数据的全面训练一次。此处，我们设置了 1024 的批大小，使用了 120 个轮数，在下图即可看到，在大约

100 个轮数之后，精度并没有明显的增加。一般来说，看哪个参数起作用需要反复试验才知道。现在我们用 fit() 方法来拟合模型。

```
Epochs = 120
Batch_size = 1024

hist = model.fit(x_train, y_train, batch_size=Batch_size, epochs=
                            Epochs, validation_data=(x_val, y_val))

plt.figure(figsize=(20,5))
plt.subplot(121)
plt.plot(hist.history['acc'])
plt.plot(hist.history['val_acc'])
plt.title('model accuracy')
plt.ylabel('accuracy')
plt.xlabel('epoch')
plt.legend(['train', 'validation'], loc='upper left')

plt.subplot(122)
plt.plot(hist.history['loss'])
plt.plot(hist.history['val_loss'])
plt.title('model loss')
plt.ylabel('loss')
plt.xlabel('epoch')
plt.legend(['train', 'validation'], loc='upper right')
plt.show()
```

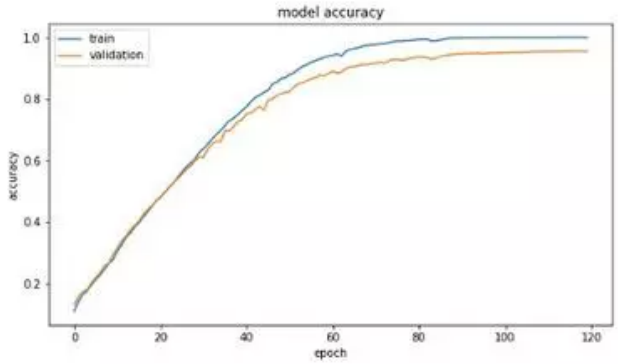

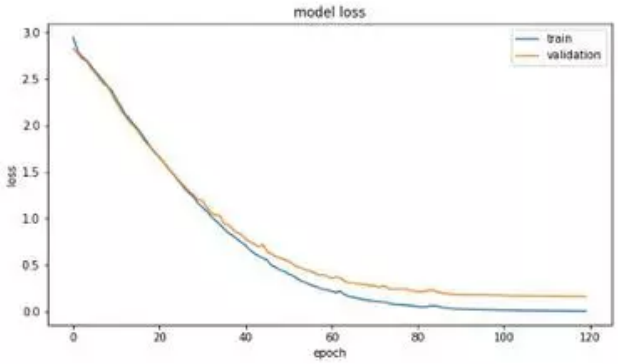

最后，从上面的图表可以看出，在验证集上我们可以得到大约 93% 的准确率，结果似乎并不坏。当然，如果我们增大训练数据的规模，还可以做得更好。下面是对一组随机选择的单词的预测。

.-*-..*-..*..*-.-.*-*..*---*-.	addiction	addiction
-...*.*-..*..-.*.-..*---*.--*.*.-.	bedflower	bedflower
.*.--.*---*-.*-.--*--*---*..-*...	eponymous	eponyoous
-...*.*-.*.*-..*..*-.-.*-*.-	benedicta	benedicta
-..*..*...*..-*.-..*..-.*..*-..*.	disulfide	disulfude
..*-.*-*.*.-.*-*..*.-..*.-..	intertill	intertill
-.*---*-.*--*---*-.*..*...*-	nonmonist	nonmonist
-.-.*..*-.*--.-*..-*.*-..*.*.-	cinquedea	cinqueria
-.-.*.*.-.*.*-...*.-.*---*...*.	cerebrose	cerebrose
-...*.-.*.-*...-*.-*-..*---*.*...	bravadoes	bravadoes
-..*.-*.-.*-.-*.-..*..*.*...*-	darkliest	darkliest
.-.*.-*-.*--.*..*-.*.*...*...	ranginess	ranginess
.-.*.*...*..*.-..*..*.-*-*.	resiliate	resiliate
...*.--*.*.*-*.--*---*---*-..	sweetwood	sweetwood
.-..*.*-.-.*....*.*.-.*---*..-*...	lecherous	lecherous
-..*.--*.-*.-.*..-.*.-..*..*-.*--.	dwarfling	dwarfling
....*---*.-..*.-..*-.--*....*---*-.-.*-.-	hollyhock	hollybock
-...*.-.*.-*..*-.*.-..*.*...*...	brainless	brainless
....*---*-.*.*...*-*.*...*-	honestest	honestest
.-..*..-*-*.-*-.-.*.*---*..-*...	lutaceous	lutaceous

在左边输入代码，中间输入相应的单词，右边输入预测。如果预测正确，那么该单词为绿色，否则为红色。

正如你所看到的，错误的预测也不算太坏。我们必须提醒自己，破译密码并没有破解代码，也就是说，弄清楚每个字母代表什么。事实上，我们可以输入字母的代码，并查看网络预测的单个字母的代码，如下所示，我们离目标还很远！

```
a rerclothh
b veeceayhh
c peeceayhh
d fercrofhh
e eerrlahhh
f feeceayhh
g ceecrethh
h veeceayhh
i eerclohhh
j zeeeeeesh
k cercrethh
l feeceayhh
m ceecrethh
n rerclothh
o zeeereesh
p peecreyhh
q zeerrethh
r rercrofhh
s fercfofhh
t rracrethh
u rerclofhh
v veecrayhh
w ceerrethh
x peecrayhh
y zeerrethh
z beecreohh
```

作为 encoder-decoder 模型的另一个例子，你可以尝试使用凯撒加密（Caesar cipher）或者其他代码来查看这种方法的有效性如何。

AI 前线：凯撒加密，或称恺撒加密、恺撒变换、变换加密，是一种最简单且最广为人知的加密技术。它是一种替换加密的技术，明文中的所有字母都在字母表上向后（或向前）按照一个固定数目进行偏移后被替换成密文。例，当偏移量是 3 的时候，所有的字母 A 将被替换成 D，B 变成 E，以此类推。这个加密方法是以凯撒的名字命名的，当年凯撒曾用此方法与其将军们进行联系。凯撒密码通常被作为其他更复杂的加密方法中的一个步骤。凯撒密码还在现代的 ROT13 系统中被应用。但是和所有的利用字母表进行替换的加密技术一样，凯撒密码非常容易被破解，而且在实际应用中也无法保证通信安全。

References:

[1] Sequence to Sequence Learningwith Neural Networks

http://papers.nips.cc/paper/5346-sequence-to-sequence-learning-with-neural-networks.pdf

[2] Understanding LSTM Networks

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

[3] THE MARKOV CHAIN MONTE CARLO REVOLUTION

http://www.ams.org/journals/bull/2009-46-02/S0273-0979-08-01238-X/S0273-0979-08-01238-X.pdf

AI前线

紧跟前沿的AI技术社群

想看更多这类文章， 请给我们点个赞吧！

喜欢此内容的人还喜欢

逃离互联网“围城”：曾经我以为自己站在了风口

AI前线

8件事证明，中国人现在什么都不信了